

Econometria e Séries Temporais - Aula 3 -

Prof. Mestre. Omar Barroso

Instituto Brasileiro de Educação, Pesquisa e Desenvolvimento

Revisão

- Na aula passada vimos diversos exemplos de processos estacionários e seus padrões como:
- *Ruído Branco Gaussiano (RBG)*
- *Violação de Estacionariedade.*
- *Padrão Determinístico.*
- *Passeio Aleatório e flutuações.*
- Todavia, de uma maneira empírica como podemos determinar se uma série temporal demonstra estacionariedade? Para isso utilizamos o teste “*Augmented Dickey Fuller Test*” ou mais conhecido como **ADF**.

ADF

- O teste Augmented Dickey-Fuller (ADF) é uma ferramenta fundamental na análise de séries temporais. Seu propósito é determinar se uma dada série temporal é estacionária ou exibe uma **raiz unitária (RU)**, o que indica não estacionariedade.
- A RU caracteriza uma série temporal não-estacionária
- Em termos técnicos, uma RU existe quando um coeficiente de defasagem 1 (α) é igual a 1:
- $y_t = \alpha y_{t-1} + x_e$
- Se $\alpha \neq 1$, a série temporal é estacionária, caso contrário, a série é não estacionária.

ADF Metodologia

- O teste Dickey Fuller sugere que existe um modelo de série temporal autorregressiva [de tipo 1] representado matematicamente de tal maneira:
- $y_t = \mu + \psi_1 y_{t-1} + \varepsilon_t$
- Subtraindo y_{t-1} de ambos os lados temos:
- $\Delta y_t = \mu + \delta_1 y_{t-1} + \varepsilon_t$
- Desta maneira, o teste Dickey Fuller nos apresenta um teste 't' para avaliar a estacionariedade de uma série AR(1).
- $t_{\hat{\delta}} = \frac{\hat{\delta}}{SE(\hat{\delta})}$

ADF Metodologia

- o ADF é utilizado para um conjunto maior de modelos de séries temporais mais complexas.
- O teste Dickey Fuller aumentado assume um modelo de série temporal do tipo AR(p) e é representado matematicamente como,

$$y_t = \mu + \sum_{i=1}^p \varphi_i y_{t-1} + \varepsilon_t$$

- Subtraindo y_{t-1} de ambos os lados temos,

$$\Delta y_t = \mu + \delta y_{t-1} + \sum_{i=1}^p \beta_i \Delta y_{t-1} + \varepsilon_t$$

ADF Metodologia

- ADF é a mesma equação que DF, com a única diferença sendo a adição de termos diferenciais que representam uma série temporal maior.


$$t_{\hat{\beta}_i} = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

Hipóteses

- H_0 : A série temporal é não estacionária. Em outras palavras, ela tem alguma estrutura dependente do tempo e não tem variância constante ao longo do tempo. Ela apresenta RU.
- H_a : A série temporal é estacionaria.
- Caso H_0 seja rejeitada e Podemos dizer que a série apresenta um padrão estacionário.
- Em outras palavras, caso H_a falhe em ser rejeitada teremos um padrão estacionário.

Exemplo rudimentar


- Para tal série, temos os seguintes resultados do ADF:
- Ou seja, de acordo com os resultados calculados pelo R, a série apresenta:
- Falhamos em rejeitar H_0 , dado que o valor p é menor do que 0.05.
- Ou seja, a série temporal é não estacionária, dado que não apresenta variância constante sobre o tempo.



```
Augmented Dickey-Fuller Test data:  
data Dickey-Fuller = -2.2048,  
Lag order = 2,  
p-value = 0.4943  
alternative hypothesis: stationary
```



Exemplo mais complexo (Câmbio USD/GBP)

- Baixando pela biblioteca FRED[R] obtemos a série da taxa de câmbio referente ao dólar norte-americano vs. libra esterlina britânica.



Exemplo mais complexo (Câmbio USD/GBP)

- Em séries financeiras costumamos calcular a diferença dos valores passados com o mais presentes para obter um padrão de retornos. Com a função 'diff' no R obtemos esse padrão rapidamente.



Exemplo mais complexo (Câmbio USD/GBP)

- Por último, vamos avaliar com o teste ADF se de fato temos um padrão estacionário.
- A estatística de teste (Dickey-Fuller) é -22,489.
- Neste caso o valor do teste se desvia da hipótese nula de não estacionariedade (presença de uma raiz unitária).
- Uma estatística de teste mais negativa indica evidências mais fortes contra a hipótese nula.
- O valor p associado ao teste é 0,01.
- A hipótese alternativa afirma que a série é estacionária.
- Neste caso, a hipótese alternativa falha em ser rejeitada pelo seu baixo valor p.
- Em resumo, sua série temporal parece ser estacionária com base no teste ADF.

```
Augmented Dickey-Fuller Test data:  
usd_ukp_diff_clean Dickey-Fuller = -22.489,  
Lag order = 23,  
p-value = 0.01  
alternative hypothesis: stationary
```

Modelos AR(1)


- Os **modelos autorregressivos** (AR) são comuns em projeções econômicas e financeiras. Um modelo autorregressivo é relacionado a variável de uma série de tempo com seus **valores históricos (ou do passado)**. Nesse contexto, a variável do passado deve prever o futuro.
- O modelo AR mais simples utiliza apenas o resultado mais recente da série temporal observada para prever valores futuros.
- Para uma série temporal Y_t , o modelo é chamado de modelo **AR de primeira ordem**. Em outras palavras, **AR(1)**, aonde 1 indica que a ordem do AR é um.
- AR(1) representa a população da série de tempo Y_t , conforme a equação (1).

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + u_t$$

Exemplo: Projeções PIB (EUA)

- Vamos utilizar a denominação do PIB em inglês “GDP (*Gross Domestic Product*)”.
- Para a série de crescimento do PIB, o modelo AR(1) utiliza apenas a informação sobre o crescimento do PIB observado durante o último trimestre para prever uma taxa de crescimento futura.
- O AR(1) do modelo de crescimento do PIB, pode ser estimado pelo cálculo do MQO sobre a regressão $GDPGR_t$ em $GDPGR_{t-1}$.
- GDPGR (GDP Growth Rate) ou Taxa de Crescimento do PIB.

$$\widehat{GDPGR}_t = \hat{\beta}_0 + \hat{\beta}_1 GDPGR_{t-1}$$



Exemplo: Projeções PIB (EUA)

- Primeiro, convertemos os dados do PIB em um objeto de série temporal, começando em 1947 com uma frequência trimestral (4 trimestres por ano).
- Logo após, estimamos o modelo AR(1) como a função 'ar.ols'. Com isso, 'order.max = 1' especifica que você está ajustando um modelo AR de ordem 1 (AR(1)). O termo, 'intercept = T' indica que o modelo deve incluir um termo de intercepto, e 'demean = F' sugere que a média da série não deve ser rebaixada antes da estimativa.

```
Call: ar.ols(x = gdp_ts, order.max = 1, demean = F,
intercept = T) Coefficients: 1 1.0043 Intercept: 24.52
(16.2) Order selected 1 sigma^2 estimated as 21829
```

Os resultados demonstram que o coeficiente para o termo AR(1), que é aproximadamente 1,0043, e o termo do intercepto é 24,52.

Versão defasada da série temporal do PIB (EUA)

- Criamos manualmente uma versão defasada da série temporal do PIB (lag_GDPC1) e então ajustamos um modelo linear usando lm com a fórmula `gdp_ts ~ lag_GDPC1`. Isso é equivalente a um modelo AR(1), mas em vez de usar `ar.ols`, ele usa a estrutura geral do modelo linear.
- A saída `summary(ar_lm)` mostra que o coeficiente AR(1) é exatamente 1,000 com um intercepto próxima de zero, o que sugere uma relação autorregressiva sólida.
- A mensagem de aviso "*ajuste essencialmente perfeito: o resumo pode não ser confiável*" sugere que o modelo tem um ajuste quase perfeito, provavelmente porque o coeficiente AR(1) é muito próximo de 1, o que implica que a série do PIB pode ser não estacionária.

Call:

```
lm(formula = formula, data = gdp_ts)
```

Residuals:

Min	1Q	Median	3Q	Max
-8.971e-11	7.400e-14	3.380e-13	5.840e-13	6.141e-12

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-8.265e-12	5.639e-13	-1.466e+01	<2e-16 ***
lag_GDPC1	1.000e+00	4.794e-17	2.086e+16	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.156e-12 on 308 degrees of freedom

Multiple R-squared: 1, Adjusted R-squared: 1

F-statistic: 4.352e+32 on 1 and 308 DF, p-value: < 2.2e-16

Média Móvel ou 'Moving Average (MA)'

- Uma média móvel é uma técnica estatística utilizada para suavizar flutuações de curto prazo e destacar tendências ou ciclos de longo prazo em uma série de dados.
- Essa técnica envolve calcular a média de um número fixo de pontos de dados consecutivos em uma série temporal e, então, "mover" essa janela por todo o conjunto de dados para criar uma nova série de valores médios.
- A média móvel simples é calculada a partir da média aritmética dos dados dos últimos "n" dias.


$$SMA_t(n) = \frac{P_t + \dots + P_{t-n+1}}{n}$$

Métodos


- Suavização: Ao calcular a média de pontos de dados em uma janela especificada, uma média móvel suaviza o ruído (flutuações aleatórias) na série temporal, facilitando a observação de tendências subjacentes.
- Tamanho da janela (k): O número de pontos de dados consecutivos usados para calcular cada média é conhecido como tamanho da janela ou período. Por exemplo, uma média móvel de 4 períodos em dados trimestrais faria a média de quatro trimestres de dados.

Exemplo PIB

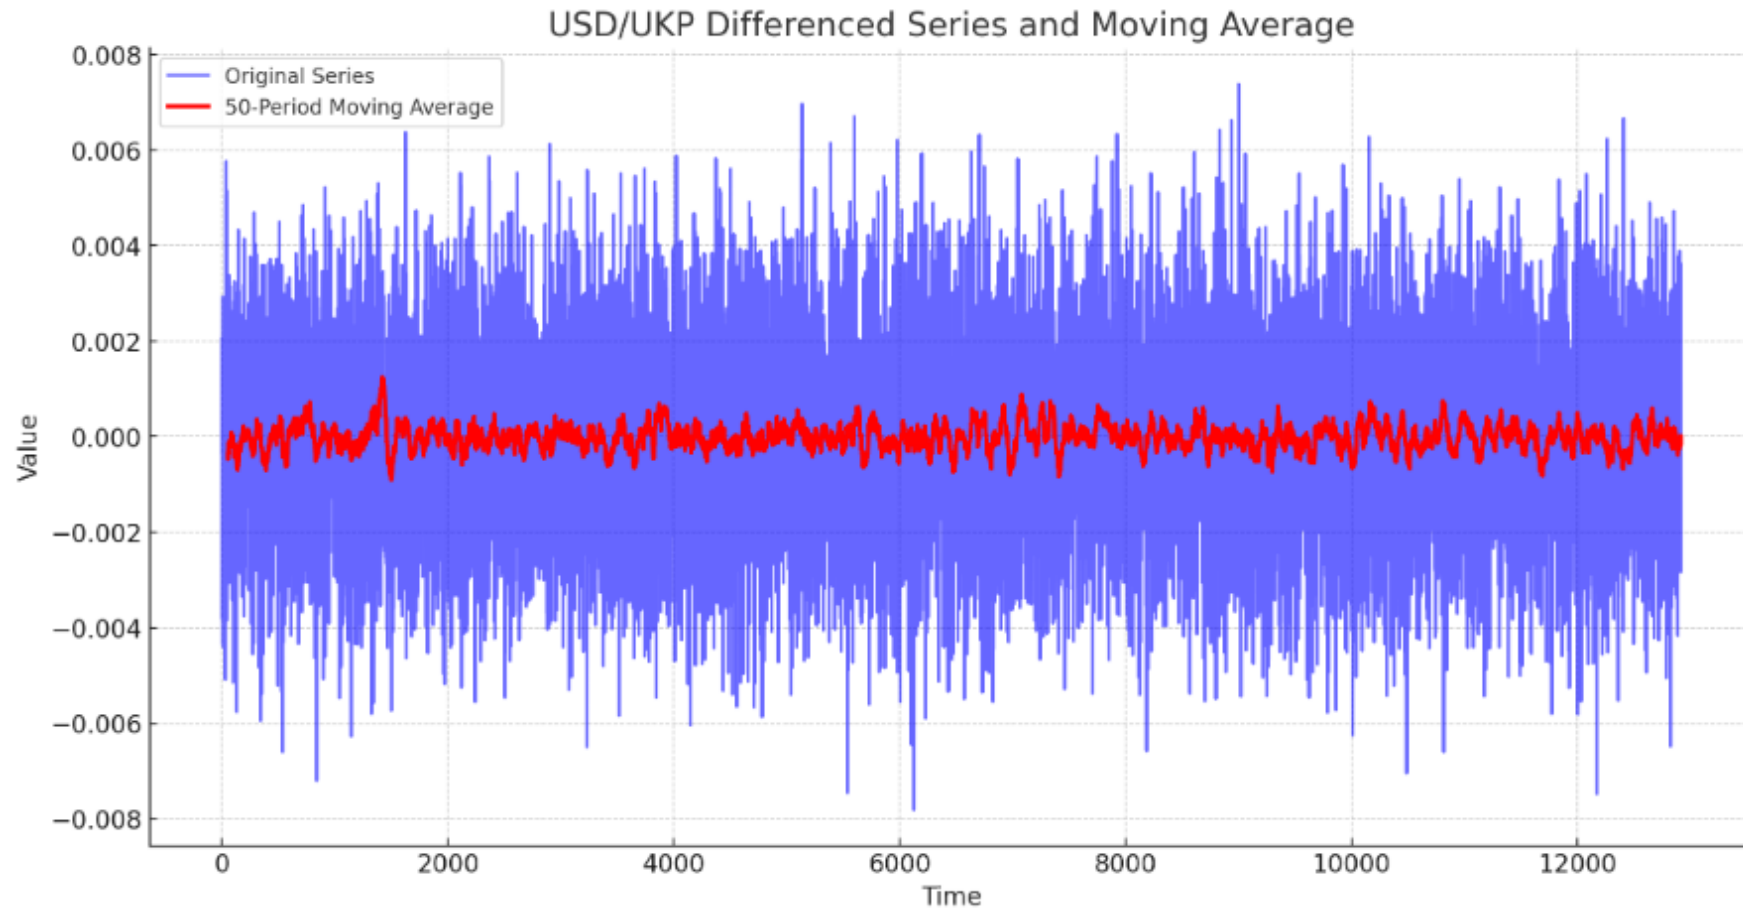
- O gráfico de linha exibindo os dados originais do PIB e a média móvel de 4 trimestres, permitindo visualizar como a tendência do PIB se suaviza com a média móvel.
- Percebe-se pelo gráfico uma comparação visual entre os dados brutos do PIB e sua tendência suavizada ao longo do tempo.
- Mas a suavização não está muito diferente da série original.
- Isso ocorre pois não diferenciamos os dados defasados com os 'presentes'.




Exemplo USD/GBP



Exemplo USD/GBP com 50 pontos





Fonte: Technical
Analysis with R

AutoRegressive Moving Average (ARMA)

- Juntando o AR com o MA...
- **Componente AutoRegressivo (AR):** O modelo regride o valor atual da série em seus próprios valores passados. Ele captura a relação entre uma observação e um número de observações defasadas.
- **Componente Média Móvel (MA):** Esta parte do modelo **usa erros de previsão anteriores em um modelo semelhante a regressão**. Ele captura a relação entre uma observação e um número de erros de previsão defasados.

Metodologia e usos

- **Modelagem e Previsão de Dados de Séries Temporais:** É útil para prever dados que mostram um padrão claro de tendência ou sazonalidade.
- **Captura de Autocorrelação:** Modela a autocorrelação nos dados, por exemplo, como os valores atuais se relacionam com valores passados e **erros passados**.
- **Descrição e Compreensão da Dinâmica:** Ajuda a entender a dinâmica subjacente da série temporal, como valores passados influenciam o presente.

Metodologia

- *p*: O número de observações defasadas incluídas no modelo (parte AR).
- *q*: O número de erros de previsão defasados incluídos no modelo (parte MA).
- Assim, ARMA (p,q):
- $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t$
- y_t : A série temporal no tempo 't'.
- ϕ_n : Coeficiente AR.
- θ_n : Coeficiente MA.
- ε_t : Ruído branco no tempo 't'.


Econometria e Séries Temporais - Aula 4 -

Prof. Mestre. Omar Barroso

Instituto Brasileiro de Educação, Pesquisa e Desenvolvimento


Exemplo – resíduos Câmbio USD/GBP

- Podemos ver que o resíduos (erros) seguem um padrão semelhante a diferenciação da mesma série.
- Isso significa diversos fatores, pelos quais vamos discutir...



Exemplo – resíduos Câmbio USD/GBP

- O Gráfico de autocorrelação demonstra que os picos não estão muito acima da linha tracejada.
- Podemos sugerir que nossa série é estatisticamente não significativa, ou que existem indícios contra a autocorrelação?
- Vamos analisar com mais profundidade...



Teste de Box-Ljung

- O teste Box-Ljung é um teste estatístico comumente usado em econometria para avaliar se os resíduos de um modelo de série temporal são distribuídos de forma independente.
- Ele testa especificamente a autocorrelação em múltiplos atrasos nos resíduos.
- A autocorrelação nos resíduos sugere que o modelo pode estar especificado incorretamente, o que significa que ele não capturou totalmente a dinâmica subjacente da série temporal.

Teste de Box-Ljung

- Hipótese nula (H_0): a hipótese nula do teste Box-Ljung é que não há autocorrelação nos resíduos até um certo número de defasagens, denotado como h . Em outras palavras, os resíduos são distribuídos independentemente.
- Hipótese alternativa (H_1): a hipótese alternativa é que existe autocorrelação nos resíduos em uma ou mais das defasagens testadas.

Teste de Box-Ljung

- Os resultados do teste Ljung-Box para os resíduos do modelo ARMA fornecem informações sobre se os resíduos (ou seja, as diferenças entre os valores observados e ajustados) são independentes (não correlacionados) ao longo do tempo.
- Box-Ljung test
- data: residuals(arma_model)
- X-squared = 25.4, df = 20, p-value = 0.1866


Teste de Box-Ljung

- Q = teste estatístico
- N = Número de observações.
- \hat{r}_k = Autocorrelação da amostra sobre a defasagem \hat{r} .
- H = número de defasagens sendo testadas.

$$Q = n(n + 2) \sum_{k=1}^h \frac{\hat{r}_k^2}{n-k}$$

Teste de Box-Ljung

- Q = segue uma distribuição chi quadrado (χ^2) com h graus de Liberdade.
- Um valor grande de Q indica que os resíduos não são distribuídos de forma independente, indicando a presença de autocorrelação.



Fonte: Digital Calculator (AUS)

Teste de Box-Ljung

- No exemplo, o valor p é 0,1866, que é maior que 0,05. O que significa **que não conseguimos** rejeitar a hipótese nula.
- Portanto, **não há evidência de autocorrelação significativa nos resíduos** do ARMA.
- Um valor p de 0,1866 indica que os resíduos não apresentam autocorrelação significativa.

- Box-Ljung test
data: residuals(arma_model)
X-squared = 25.4, df = 20, p-value = 0.1866

Teste de Box-Ljung


- Isto sugere que os resíduos estão a comportar-se como **ruído branco**, o que significa que são **independentes e distribuídos de forma idêntica**.
 - Não há evidências fortes que sugiram que quaisquer defasagens ou alterações adicionais na estrutura do modelo sejam necessárias para explicar a autocorrelação.
- Box-Ljung test
data: residuals(arma_model)
X-squared = 25.4, df = 20, p-value = 0.1866

Capturando Autocorrelação

- Quando um modelo **ARMA captura a autocorrelação** nos dados, significa que o modelo identificou e modelou com sucesso os padrões como valores e erros passados afetam o valor atual.
- Este é um **objetivo fundamental** da modelagem de séries temporais: explicar o máximo possível da estrutura dos dados usando informações passadas.

Resíduos como Ruído Branco

- Os resíduos que se comportam como ruído branco **não são correlacionados** e possuem uma média e variância constantes. Em essência, eles são puramente aleatórios, sem padrão discernível.
- Implicação: se os resíduos do seu modelo são ruído branco, isso sugere que o modelo fez um bom trabalho ao capturar todos os padrões sistemáticos nos dados. Não há autocorrelação restante, o que significa que o modelo explicou efetivamente a série temporal.
- Isso é considerado um sinal de um modelo bem ajustado porque qualquer estrutura restante nos resíduos indicaria que o modelo perdeu algum padrão nos dados.



Interpretando os Resultados (ARMA)

- ARMA(1,1) indica um termo autorregressivo (AR(1)) e um termo de média móvel (MA(1)).
- Os coeficientes que devemos prestar atenção:
- $ar1 = 0,0209$: O coeficiente autorregressivo para o atraso 1.
- $ma1 = 0,0198$: O coeficiente da média móvel para o atraso 1.
- $intercept = -0,0001$: A média estimada da série.

Interpretando os Resultados (ARMA)

Coeficiente AR(1) ($ar1 = 0,0209$)

- O coeficiente autorregressivo $ar1$ representa a influência da observação anterior (atraso 1) na observação atual.
- Como $ar1 = 0,0209$, isso sugere que o valor da série no tempo $t-1$ tem um efeito positivo, mas muito pequeno, no valor no tempo t .
- Ou seja, um aumento de 1 unidade no valor anterior levaria a um aumento de aproximadamente 0,0209 unidade no valor atual, mantendo todo o resto constante.
- A pequena magnitude desse coeficiente indica que a série tem persistência fraca; **o valor passado tem apenas um impacto menor no valor atual.**

Interpretando os Resultados (ARMA)

- **Coeficiente MA(1) ($ma1 = 0,0198$)**
- Interpretação: O coeficiente da média móvel $ma1$ captura o impacto do erro do período anterior (atraso 1) na observação atual.
- Com $ma1 = 0,0198$, sugere que o termo de erro (ou choque) do período anterior tem uma pequena influência positiva no valor atual.
- Um choque de 1 unidade no período anterior resultaria em um aumento de $\sim 0,0198$ unidade no valor atual, *Ceteris Paribus*.
- Assim como o coeficiente AR, esse pequeno valor indica que os choques no período anterior têm um efeito mínimo no período atual.

Interpretando os Resultados (ARMA)

- **Intercepto (intercepto = -0,0001):**
- O intercepto representa o nível médio da série quando os termos autorregressivo e de média móvel são contabilizados.
- Nesse caso, o intercepto é muito próximo de zero (-0,0001), sugerindo que a série temporal oscila em torno de um valor médio próximo de zero quando os efeitos dos componentes AR e MA são removidos.
- Esse pequeno valor indica que há pouca ou nenhuma tendência de longo prazo nos dados.

Interpretando os Resultados (ARMA)

- Os erros padrão são relativamente grandes em comparação aos coeficientes, sugerindo que há alguma incerteza em torno dessas estimativas, o que é comum em modelos de séries temporais com valores de coeficientes baixos.

Interpretação (ARMA)

- O modelo ARMA(1,1) indica que **a série temporal tem fraca dependência dos valores passados** e choques anteriores, com os componentes AR e MA tendo pequenos coeficientes positivos.
- Isso sugere que a série é relativamente estável, com impactos pequenos e de curta duração de observações e choques passados.
- A interceptação próxima de zero indica ainda que a série não tem uma forte tendência ascendente ou descendente ao longo do tempo.

Interpretação (ARMA)

- Estatísticas de Ajuste: log likelihood = 41757.55.
- Ligeiramente menor que o do modelo ARIMA(2,0,2), sugerindo um ajuste marginalmente pior.
- AIC = -83507.11: Maior que o ARIMA(2,0,2), sugerindo que este modelo é menos preferível.

ARIMA (Autoregressive Integrated Moving Average)

- O modelo ARIMA, que significa **Média Móvel Integrada Autoregressiva**, é um método estatístico/econométrico para analisar e prever dados de séries temporais.
- É particularmente útil para modelar dados que mostram evidências de *não estacionariedade*, onde as propriedades estatísticas como média e variância mudam ao longo do tempo.

ARIMA (Objetivo e aplicações)

- **Previsão:** os modelos ARIMA são amplamente usados para prever valores futuros com base em observações passadas.
- **Análise de tendências:** ao analisar as **séries diferenciadas**, os modelos ARIMA ajudam a identificar tendências e padrões subjacentes.
- **Análise econométrica:** Podemos aplicar o ARIMA em vários indicadores econômicos/financeiros, como, Preços de ações, PIB, taxas de inflação e taxas de desemprego. Com isso, podemos prever tendências futuras e avaliar políticas econômicas e estratégias de investimentos.

Componentes ARIMA

- **Componente AR (AutoRegressivo):**
- A parte AR envolve a regressão da variável em seus próprios valores anteriores (lags). Por exemplo, um modelo AR(1) usa o valor imediatamente anterior para prever o valor atual.
- Em notação matemática:
- $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$
- No qual, ϕ_1, \dots, ϕ_n são coeficientes autorregressivos e ε_t representa o termo de erro ou ruído branco.

Componentes ARIMA

- **Componente Integrado**
- O "I" em ARIMA se refere à diferenciação dos dados para torná-los estacionários. Séries temporais não estacionárias podem ser tornadas estacionárias subtraindo a observação anterior da observação atual, um processo chamado diferenciação.
- O grau de diferenciação é denotado por d , onde d representa o número de vezes que os dados foram diferenciados.
- Por exemplo, se $d=1$, o modelo trabalha com a diferença entre observações consecutivas. $y'_t = y_t - y_{t-1}$.

Componentes ARIMA

- **Componente MA**
- $y_t = \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$
- θ_n : Coeficiente MA.
- ε_t : Ruído branco no tempo 't'.

Representação ARIMA

- P: Número dos termos autorregressivos.
- D: Número das operações de diferenciação e o quanto é necessário para tornar um processo estacionário.
- Q: Número dos termos MA.
- \therefore ARIMA (p,d,q).

ARIMA estágio (1,0,1) resultados

- $ar1 = 0,0209$: A primeira defasagem da série tem uma pequena influência positiva no valor atual.
- $ma1 = 0,0198$: A primeira defasagem do erro de previsão tem um pequeno efeito positivo no valor atual.
- $intercept = -1e-04$: A média da série, muito próxima de zero, indicando que a série está centrada em zero.

ARIMA estágio (1,0,1) resultados

- Os erros padrão para $ar1$ e $ma1$ são maiores em comparação com os do modelo ARIMA(2,0,2), indicando mais incerteza nessas estimativas.
- $\sigma^2 = 9.157e-05$: Um pouco maior que no modelo ARIMA(2,0,2), sugerindo um ajuste um pouco pior.
- Log likelihood = 41757,55: Inferior ao modelo ARIMA(2,0,2), indicando pior ajuste.
- AIC = -83507,11: Maior que no modelo ARIMA(2,0,2), sugerindo que este modelo é menos preferido de acordo com o critério AIC.

ARIMA estágio (2,0,2) resultados

- Este modelo possui 2 termos autoregressivos (AR) e 2 termos de média móvel (MA).
- $ar1 = -0,2673$, $ar2 = -0,7193$: Estes são os coeficientes para os termos autoregressivos. Os valores negativos sugerem que os valores passados da série (especificamente a primeira e a segunda defasagens) têm uma relação inversa com o valor atual da série.

ARIMA estágio (2,0,2) resultados

- $ma1 = 0,3004$, $ma2 = 0,7360$: Estes são os coeficientes para os termos da média móvel. Valores positivos indicam que o valor atual da série é influenciado positivamente por erros de previsão passados.
- $média = -1e-04$: Esta é a média estimada da série, que é muito próxima de zero.
- Os erros padrão fornecem uma medida da incerteza em torno dos coeficientes estimados. Por exemplo, o erro padrão para $ar1$ é $0,0908$, sugerindo que a estimativa é relativamente precisa.

ARIMA estágio (2,0,2) resultados

- $\sigma^2 = 9.152e-05$: representa a variância dos resíduos (erros) do modelo. Um valor mais baixo sugere que o modelo se ajusta bem aos dados.
- Log Likelihood = 41763,38: mede o ajuste do modelo, com valores mais altos indicando um melhor ajuste.
- AIC = -83514,76, BIC = -83469,96: São critérios de informação utilizados para comparação de modelos. Valores mais baixos indicam um melhor ajuste do modelo em relação a outros modelos.

Comparação (1,0,1) vs. (2,0,2)

- **Preferência do modelo:** O modelo ARIMA (2,0,2) é provavelmente o melhor modelo com base nos valores mais baixos de AIC, BIC e valores de log likelihood mais altos. Este modelo captura mais complexidade (com dois termos AR e dois termos MA) e parece ajustar-se melhor aos dados.
- **Resíduos:** Ambos os modelos apresentam autocorrelações nos resíduos, indicando que capturam adequadamente a estrutura subjacente dos dados.
- **Interpretação do coeficiente:** Os coeficientes no modelo ARIMA(2,0,2) sugerem que os valores passados e os erros passados têm uma influência mais forte e complexa no valor atual da série temporal em comparação com o ARIMA(1,0,1) mais simples.

Perguntas Para Revisão

- (Não precisa Entregar)
- Para o que serve o teste ADF, como interpretar os resultados?
- O que é um processo AR(1)? E como aplicar em uma série temporal?
- O que são resíduos em um modelo econométrico?
- Qual é a relação entre MA e resíduos?
- Como o ARMA é agregado como modelo?
- Nesse contexto, como o ARIMA é agregado como modelo?

Referências

- - Box, G.E.P. and Jenkins, G.M., 1970. *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day.
- - Box, G.E.P. and Jenkins, G.M., 1970. *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day.
- - Box, G.E.P. and Pierce, D.A., 1970. Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. *Journal of the American Statistical Association*, 65(332), pp.1509-1526.
- - Box, G.E.P. and Pierce, D.A., 1970. Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. *Journal of the American Statistical Association*, 65(332), pp.1509-1526.

Referências

- - Dickey, D.A. and Fuller, W.A., 1979. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366a), pp.427-431.
- - Dickey, D.A. and Fuller, W.A., 1979. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366a), pp.427-431.
- - Ljung, G.M. and Box, G.E.P., 1978. On a measure of lack of fit in time series models. *Biometrika*, 65(2), pp.297-303.
- - Ljung, G.M. and Box, G.E.P., 1978. On a measure of lack of fit in time series models. *Biometrika*, 65(2), pp.297-303.