

# Econometria e Séries Temporais - Aula 5 -


Prof. Mestre. Omar Barroso

Instituto Brasileiro de Educação, Pesquisa e Desenvolvimento

# Interpretando: Output do modelo ARIMA em R

- Na aula anterior vimos como os coeficientes  $AR(1)$ ,  $AR(2)$ ,  $Ma(1)$ ,  $Ma(2)$  e o intercepto explicam a série temporal.
- Em muitos casos, os coeficientes podem explicar a variável dependente de forma positiva ou negativa.
- Ou seja, existe uma relação de elasticidade, no qual, a variação do coeficiente afeta uma unidade da variável dependente.

# Recapitulando USD/GBP



# Interpretando: Output do modelo ARIMA em R

- Relembrando o resultado do modelo ARIMA (2,0,2) da aula anterior (taxa de câmbio USD/GBP).

Call:

```
arima(x = usd_ukp_diff_clean, order = c(2, 0, 2))
```

Coefficients:

	ar1	ar2	ma1	ma2	intercept
	-0.2680	-0.7241	0.3009	0.7407	-1e-04
s.e.	0.0826	0.1905	0.0771	0.1865	1e-04

$\sigma^2$  estimated as 9.147e-05: log likelihood = 41774.44, aic = -83536.87

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	1.605535e-05	0.009563956	0.00671401	NaN	Inf	0.7012484	0.007905228

# Interpretando: Output do modelo ARIMA em R

- Hoje veremos...
- $\text{Sigma}^2$
- Log likelihood (verossimilhança em log)
- ME: Mean Error (Erro Médio)
- AIC: Akaike Information Criterion (Crítério de Informação Akaike)
- RMSE: Root Mean Squarred Error (Raíz da Média do Erro ao Quadrado)
- MAE: Mean Absolute Error (Erro da Média Absoluta)
- MPE: Mean Percentage Error (Média Percentual do Erro)
- MAPE: Mean Absolute Percentage Error (Média Absoluta Percentual do Erro)
- MASE: Mean Absolute Scaled Error (Média Absoluta sobre o Erro Escalar)
- ACF1: Autocorrelation Function 1 (Função de Autocorrelação 1)

# Sigma<sup>2</sup> ( $\sigma^2$ )

- Esta é a variância estimada dos resíduos (erros) do modelo.
- Representando a variabilidade dos dados no qual o modelo não explica. Valores mais baixos sugerem um melhor ajuste do modelo.
- No caso do modelo USD/GBP:  $\sigma^2$  estimated as 9.147e-05
- Desta forma, a variância estimada sugere que a variabilidade do modelo é relativamente alta.
- Todavia, costumamos sugerir que a variância estimada dos resíduos do modelo não deve ser analisada solitariamente (e.g., comparar com modelos distintos ou diferentes janelas de tempo).

# Log likelihood (verossimilhança em log)

- A verossimilhança logarítmica é derivada da teoria de estimativa de **máxima verossimilhança**, que ajusta o modelo aos dados, maximizando a probabilidade de observação dos dados fornecidos.
- Esta é uma medida da qualidade do ajuste do modelo. Ele avalia a probabilidade de o modelo ter gerado os dados observados. Valores de log de probabilidade **mais altos indicam um melhor ajuste**.
- ARIMA (1,0,1): 41768.58 .V.s. ARIMA (2,0,2): 41774.44
- Qual apresenta um melhor ajuste do modelo?

# ME: Mean Error

- Esta é a diferença média entre os valores reais e os valores previstos. ME pode indicar viés no modelo – se ele superestima ou subestima consistentemente os valores.
- $(\varepsilon - \hat{\varepsilon})$



# Root Mean Square Error (RMSE)

- Esta é a raiz quadrada da média das diferenças quadradas entre os valores reais e previstos (erros).

- $$\sqrt{\left(\frac{\sum_{i=1}^n (\varepsilon - \hat{\varepsilon})^2}{n}\right)}$$

- O RMSE penaliza mais erros maiores do que erros menores. Um RMSE **mais baixo** indica melhor precisão preditiva.
- ARIMA (1,0,1): -6.660123e-09 .V.S. ARIMA (2,0,2): 1.605535e-05

# Mean Absolute Error (MAE)

- Mede a magnitude média dos erros sem considerar sua direção (ou seja, positiva ou negativa). Ele fornece uma medida direta do tamanho do erro. **Valores mais baixos** indicam melhor desempenho do modelo.
- ARIMA (1,0,1): 0.006716458 .V.S. ARIMA (2,0,2): 0.00671401
- Ambos os modelos apresentam padrões similares...
- Qual modelo é melhor?

# Mean Percentage Error (MPE)

- Este é o erro percentual médio entre os valores reais e previstos. Ajuda a compreender o tamanho relativo ao erro, mas pode ser enganoso se os valores ultrapassarem zero.
- ARIMA (1,0,1):NaN .V.S. ARIMA (2,0,2):NaN
- O “NaN” ocorre quando há uma divisão por zero ou quando um ou mais valores reais no conjunto de dados são zero.
- Isso sugere que o modelo não é adequado para avaliar o desempenho por meio de medidas de erro baseadas em porcentagem nos casos em que os valores reais são zero. Outras medidas de erro como MAE ou RMSE devem ser utilizadas.

# Mean Absolute Percentage Error (MAPE)

- Este é o erro médio absoluto expresso como uma percentagem dos valores reais, fornecendo uma medida normalizada da precisão da previsão. **Menor MAPE** indica melhor desempenho.
- ARIMA (1,0,1): Inf .V.S. ARIMA (2,0,2):Inf
- Um **MAPE infinito** sugere que o desempenho do modelo não pode ser avaliado adequadamente usando MAPE quando o conjunto de dados **contém valores zero**.
- Nesses casos, outras métricas de erro como MAE ou RMSE, que não envolvem cálculos percentuais, devem ser utilizadas para avaliar a precisão do modelo.

# Erro Médio Absoluto em Escala (MASE)

- Esta é uma medida de erro normalizada que compara o MAE do modelo com o MAE de um **modelo ingênuo** (por exemplo, um modelo de passeio aleatório simples). **Valores menores que 1** indicam que o modelo tem desempenho melhor que o benchmark ingênuo.
- ARIMA (1,0,1): 0.7015041 .V.S. ARIMA (2,0,2): 0.7012484
- Ambos apresentam um valor menor do que 1.
- Desta maneira, ambos modelos tem um desempenho melhor do que o benchmark ingênuo.

# Autocorrelation Function 1 (ACF1)

- Mede a correlação entre os resíduos (erros) na defasagem 1 (ou seja, o período anterior). **Se ACF1 estiver próximo de 0**, sugere que o modelo **capturou a maior parte da autocorrelação** nos dados. Valores **diferentes de zero** sugerem autocorrelação remanescente, indicando que pode ser necessária melhoria do modelo.
- ACF1 refere-se às propriedades de autocorrelação de séries temporais, verificando se o modelo deixa alguma autocorrelação não contabilizada, que idealmente deveria ser próxima de zero em um modelo bem especificado.

# Autocorrelation Function 1 (ACF1)

- ARIMA (1,0,1):  $-8.067696e-05$  .V.S. ARIMA (2,0,2): 0.007905228.
- Lembrando: **Se ACF1 estiver próximo de 0**, sugere que o modelo **capturou a maior parte da autocorrelação** nos dados.
- Valores **diferentes de zero** sugerem autocorrelação remanescente, indicando que pode ser necessária melhoria do modelo.
- Qual modelo teve uma performance melhor?

# Akaike Information Criterion (AIC)

- É uma medida usada para avaliar a **qualidade do ajuste do modelo** enquanto penaliza pela complexidade.
- Ajuda a **selecionar o melhor modelo** de um conjunto de modelos, equilibrando ajuste e complexidade. Um **valor AIC mais baixo** indica um modelo melhor.
- $AIC = 2k - 2 \ln(L)$
- $K$  = O número de parâmetros no modelo (incluindo AR, MA e termos constantes).
- $L$  = O valor maximizado da função de verossimilhança para o modelo.



# Akaike Information Criterion (AIC)

- A AIC está enraizada na teoria da informação, especificamente no conceito de **entropia (aleatoriedade em um sistema)**. O objetivo é estimar a qualidade relativa dos modelos estatísticos para um determinado conjunto de dados, considerando tanto o ajuste (por meio da função log-verossimilhança) quanto a simplicidade do modelo (penalizando por mais parâmetros).
- Trade-off: A AIC equilibra dois objetivos concorrentes – minimizar o erro (ajuste) e evitar o ajuste excessivo (penalidade pela complexidade).

# Akaike Information Criterion (AIC)

- Seleção de modelos: Entre um conjunto de modelos, aquele com o AIC mais baixo é considerado o melhor, embora não forneça uma medida absoluta da qualidade do modelo.
- Em resumo, o AIC é um critério amplamente utilizado em análise de séries temporais e econometria para comparar modelos ARIMA e selecionar o mais apropriado.

# Akaike Information Criterion (AIC)

- ARIMA (1,0,1):-83529.15 .V.S. ARIMA (2,0,2):-83536.87
- Qual apresenta um AIC mais adequado?

# Afinal Qual Modelo Foi Melhor?

- Sigma: O modelo (1,0,1) apresenta uma variância um pouco mais alta.
- Log likelihood: A probabilidade do modelo (2,0,2) é melhor ajustada.
- ME: Aparentemente o modelo (1,0,1) apresenta mais vieses.
- RMSE: O ARIMA(1,0,1) indica uma precisão preditiva melhor.

# Afinal Qual Modelo Foi Melhor?

- MAE: O modelo (2,0,2) é relativamente menor. Ou seja a magnitude dos erros aparenta ser [relativamente] menos influenciada.
- MPE: Não adequado para ambos modelos.
- MAPE: Não adequado para ambos modelos.
- ACF1: O modelo (2,0,2) capturou melhor a autocorrelação nos dados.
- AIC: A qualidade do modelo (2,0,2) é mais adequado equilibrando melhor pela entropia e complexidade.

# Conclusão

- Podemos dizer, que o modelo (2,0,2) teve uma performance relativamente melhor.
- Nesse contexto, o modelo (2,0,2) apresenta uma variância menor, um melhor ajuste probabilístico, menores vieses, uma menor influencia dos erros, uma captura melhor de autocorrelação e um melhor equilíbrio sobre complexidades.

# Ideias para contemplar

- Como a análise dos coeficientes difere das medidas de ajuste do modelo (MAE, RSME, etc...)?
- Quais tipos diferentes de séries temporais poderíamos aplicar esse tipo de análise?
- Processos AR 1 e 2 são o suficiente para realmente capturar os impactos em uma série temporal?

# Referências

- Box, G.E.P. and Jenkins, G.M., 1970. \*Time Series Analysis: Forecasting and Control\*. San Francisco: Holden-Day.
- - Box, G.E.P. and Jenkins, G.M., 1970. \*Time Series Analysis: Forecasting and Control\*. San Francisco: Holden-Day.
- - Box, G.E.P. and Pierce, D.A., 1970. Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. \*Journal of the American Statistical Association\*, 65(332), pp.1509-1526.
- - Box, G.E.P. and Pierce, D.A., 1970. Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. \*Journal of the American Statistical Association\*, 65(332), pp.1509-1526.
- Kennedy, P. , 1986. A Guide to Econometrics, Second Edition. MIT Press.