

# Econometria e Séries Temporais - Aula 14 -

Prof. Mestre. Omar Barroso

Instituto Brasileiro de Educação, Pesquisa e Desenvolvimento

# Variáveis Instrumentais $\leftrightarrow$ Ivs (tópico especial)

- *Amplamente conhecidas pela literatura pelo seu termo em inglês (Instrumental Variables ou Ivs).*
- Modelos de regressão podem sofrer de problemas como **variáveis omitidas**, erros de medição e causalidade simultânea.
- Nesse sentido, **o termo de erro** é correlacionado com a variável de interesse e, portanto, o coeficiente correspondente é estimado de forma inconsistente.

# Variáveis Instrumentais $\leftrightarrow$ IVs

- No entanto, se os fatores omitidos não puderem ser medidos ou não estiverem disponíveis por outros motivos, a regressão múltipla não pode resolver o problema.
- O mesmo problema surge se houver causalidade simultânea. Quando a causalidade vai de X para Y e vice-versa, haverá um viés de estimativa que não pode ser corrigido pela regressão múltipla.

# Variáveis Instrumentais $\leftrightarrow$ IVs

- Uma técnica geral para obter um estimador consistente do coeficiente de interesse é a regressão de variáveis instrumentais (IV).
- Hoje, focaremos na ferramenta de regressão IV chamada mínimos quadrados de dois estágios (TSLS).

# Variáveis Instrumentais $\leftrightarrow$ IVs

- Uma técnica geral para obter um estimador consistente do coeficiente de interesse é a regressão de variáveis instrumentais (IV).
- Hoje, focaremos na ferramenta de regressão IV chamada mínimos quadrados de dois estágios (TSLS).

# O Estimador IV com um regressor e um instrumento

- Considere a seguinte regressão.

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, \dots, n$$

- onde o termo de erro  $u_i$  é correlacionado com a variável  $X_i$  ( $X$  é endógeno) tal que MQO é inconsistente para o verdadeiro  $\beta_1$ .
- No caso mais simples, a regressão IV usa uma única variável instrumental  $z$  para obter um estimador consistente para  $\beta_1$ .

# Condições Para Uma IV Válida

- A variável  $X$  e  $Z$  devem ser correlacionadas, ou seja,  $\rho_{Z_i X_i} \neq 0$ .
- O instrumento  $Z$  não pode ser correlacionado com o termo de erro. Ou seja,  $\rho_{Z_i u_i} = 0$ .

# O estimador de mínimos quadrados em dois estágios

- Como sugerido pelo seu nome, o processo procede em dois estágios. No primeiro estágio, a variação no regressor endógeno  $X$  é decomposta em um componente sem problemas que é explicado pelo instrumento
- $Z$  é um componente problemático que é correlacionado com o erro  $u_i$ . O segundo estágio usa o componente sem problemas da variação em  $x$  para estimar  $\beta_1$ .



# O estimador de mínimos quadrados em dois estágios

- O Modelo de regressão em primeiro estágio pode ser representado por:

$$X_i = \pi_0 + \pi_1 Z_i + \nu_i$$

- Aonde a variável  $\pi_1$  é o componente de  $X_i$  que é explicado por  $Z$ .
- $\nu_i$  funciona com um termo de erro que é correlacionado com  $u_i$ .

# O estimador de mínimos quadrados em dois estágios

- O Modelo de regressão em primeiro estágio pode ser representado por:  
$$X_i = \pi_0 + \pi_1 Z_i + \nu_i$$
- Utilizando os estimadores de  $\pi_0$  e  $\pi_1$  obtemos os valores preditivos  $\hat{X}$ ,  $i = 1, \dots, n$ .
- No caso de  $Z$  ser um instrumento válido,  $\hat{X}_i$  se passa como uma variável sem problemas, no sentido de  $\hat{X}$  é exógeno em uma regressão de  $Y$  em  $\hat{X}$  no qual é obtido em uma regressão de segundo estágio.

# O estimador de mínimos quadrados em dois estágios

- O segundo estágio produz  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .
- No caso de apenas um instrumento, pode se mostrar que o estimador em dois estágios de  $\beta_1$  é:

$$\hat{\beta}_1^{TSLs} = \frac{s_{ZY}}{s_{ZX}} = \frac{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})(Z_i - \bar{Z})}{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Z_i - \bar{Z})},$$

- No qual é a razão da covariância amostral entre Z e Y, para a covariância amostral entre Z e X.

Vamos praticar...

# Consumo de Cigarros

- Vamos trabalhar com a base de dados de consumo de cigarros nos EUA.
- A questão é quanto os impostos devem ser aumentados para atingir uma certa redução no consumo de cigarros. Economistas da saúde e microeconomistas usam elasticidades para responder a esse tipo de pergunta.

# Consumo de Cigarros

- Normalmente, desejamos modelar a demanda por cigarros (quantidades de cigarros consumidos) como uma função do preço.
- Mas como o preço é endógeno, usaremos impostos (taxs) como um instrumento para o preço (price).
- Também pode ser necessário transformar ou criar novas variáveis, como o preço por maço e a renda per capita, para uma melhor especificação do modelo.

# Consumo de Cigarros

- Usamos o conjunto de dados CigarettesSW que vem com o pacote AER. É um conjunto de dados de painel que contém observações sobre o consumo de cigarros e vários indicadores econômicos para todos os 48 estados federais continentais dos EUA de 1985 a 1995. Seguindo as especificações de livros e artigos que antecedem essa pesquisa, consideramos dados para a seção transversal de estados apenas em 1995.

# Consumo de Cigarros

- Estamos interessados em estimar  $\beta_1$  em:

$$\log(Q_i^{cigarettes}) = \beta_0 + \beta_1 \log(P_i^{cigarettes}) + u_i$$

- Aonde  $Q_i$  é o número dos maços de cigarro per capita vendidos.
- $P_i$  é o preço real do maço por estado  $i$ .
- A variável instrumental que utilizaremos será o regressor endógeno  $\log(p_i)$  no qual representa a parcela dos impostos sobre cigarros proveniente do imposto geral sobre vendas mensurado por dólar por maço.



# Consumo de Cigarros

- Estamos interessados em estimar  $\beta_1$  em:

$$\log(Q_i^{cigarettes}) = \beta_0 + \beta_1 \log(P_i^{cigarettes}) + u_i$$

- A ideia é que o imposto de venda é um instrumento relevante que é incluso na média dos preços do maço após o imposto.
- Também, é possível que os impostos de venda sejam exógenos dado que conforme os impostos de venda vão influenciando a quantidade vendida diretamente sobre o preço.

# Consumo de Cigarros

- Realizamos algumas transformações para obter dados de seção transversal deflacionados para o ano de 1995.
- Também calculamos a correlação amostral entre o imposto sobre vendas e o preço por maço. A correlação amostral é um estimador consistente da correlação populacional.
- A estimativa de aproximadamente de 0,614 indica que o imposto sobre vendas e  $P_i$  exibem correlação positiva, o que atende às nossas expectativas: **impostos sobre vendas mais altos levam a preços mais altos.** No entanto, uma análise de correlação como essa não é suficiente para verificar se o instrumento é relevante. Mais tarde, voltaremos à questão de verificar se um instrumento é relevante e exógeno.

# Consumo de Cigarros

- A primeira regressão é:

$$\log(P_i^{cigarettes}) = \pi_0 + \pi_1 SalesTax_i + \nu_i$$

- Estimamos esse modelo no qual o segundo estágio rodamos uma regressão LogQi em LogPi para obter os betas estimados em segundo estágio.
- O resultados da primeira regressão ficam da determinada maneira.

$$\log(\widehat{P_i^{cigarettes}}) = \underset{(0.03)}{4.62} + \underset{(0.005)}{0.031} SalesTax_i$$

- No qual o modelo sugere que os impostos de venda são variáveis com significância estatística.

# Consumo de Cigarros

- A variação de  $P_i$  é explicada por quanto pelos impostos de venda?
- Podemos utilizar o  $R^2$  para verificar essa relação, no qual 47% da variação em preços após o imposto são explicados pela variação de impostos em diferentes estados.

# Consumo de Cigarros

- Logo após rodamos a regressão em 2º estágio que nos dá os valores que procuramos.

$$\log(\widehat{Q}_i^{cigarettes}) = \underset{(1.70)}{9.72} - \underset{(0.36)}{1.08} \log(P_i^{cigarettes})$$

# Resultado IV

- Desta forma, aparentemente o modelo realiza o ajuste necessário automaticamente. conforme utilizamos a regressão IV.

```
> # executar regressão em dois estágios usando 'ivreg()'
> cig_ivreg <- ivreg(log(packs) ~ log(rprice) | salestax, data = c1995)
> coeftest(cig_ivreg, vcov = vcovHC, type = "HC1")
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	9.71988	1.52832	6.3598	8.346e-08	***
log(rprice)	-1.08359	0.31892	-3.3977	0.001411	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

# Testes de Diagnóstico

- Coeficientes:
- Intercepto: A estimativa do intercepto (9,7199) é altamente significativa ( $p < 0,001$ ). Isso mostra o log estimado de maços de cigarro vendidos quando o log do preço real (rprice) é zero.
- Log do preço real (log(rprice)): A estimativa do coeficiente para log(rprice) é -1,0836, o que significa que um aumento de 1% no preço real dos cigarros está associado a uma redução de 1,08% na quantidade de maços de cigarro vendidos (já que é em termos de log). Essa relação é estatisticamente significativa ( $p = 0,00131$ ).

```
Call:
ivreg(formula = log(packs) ~ log(rprice) | saletax, data = c1995)

Residuals:
    Min       1Q   Median       3Q      Max
-0.64619 -0.07732  0.02981  0.11283  0.41904

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   9.7199      1.5141   6.420 6.79e-08 ***
log(rprice)  -1.0836      0.3166  -3.422  0.00131 **

Diagnostic tests:
              df1 df2 statistic  p-value
Weak instruments    1  46   40.956 7.27e-08 ***
Wu-Hausman          1  45    0.314   0.578
Sargan              0 NA         NA      NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1904 on 46 degrees of freedom
Multiple R-Squared: 0.4011,    Adjusted R-squared: 0.3881
Wald test: 11.71 on 1 and 46 DF,  p-value: 0.001313
```

# Testes de Diagnóstico

- Teste de instrumento fraco:
- Estatística  $F = 40,956$ , valor  $p = 7,27e-08$ : O teste de instrumento fraco verifica se o instrumento (neste caso, `salestax`) está suficientemente correlacionado com a variável endógena (`log(rprice)`). Uma estatística  $F$  de primeiro estágio acima de 10 geralmente indica que o instrumento é forte.
- Interpretação: Como a estatística  $F$  está bem acima do limite convencional de 10 (com um valor  $p$  muito pequeno), o instrumento (`salestax`) é forte. Isso significa que `salestax` é um instrumento válido e relevante para `log(rprice)`.

```
Call:
ivreg(formula = log(packs) ~ log(rprice) | salestax, data = c1995)

Residuals:
    Min       1Q   Median       3Q      Max
-0.64619 -0.07732  0.02981  0.11283  0.41904

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   9.7199      1.5141   6.420 6.79e-08 ***
log(rprice)  -1.0836      0.3166  -3.422  0.00131 **

Diagnostic tests:
              df1 df2 statistic  p-value
Weak instruments    1  46   40.956 7.27e-08 ***
Wu-Hausman          1  45    0.314   0.578
Sargan              0 NA         NA      NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1904 on 46 degrees of freedom
Multiple R-Squared: 0.4011,    Adjusted R-squared: 0.3881
Wald test: 11.71 on 1 and 46 DF,  p-value: 0.001313
```



# Testes de Diagnóstico

- Teste de Wu-Hausman:
- Estatística Wu-Hausman = 0,314, valor  $p = 0,578$ : Este teste avalia se o regressor endógeno ( $\log(rprice)$ ) está correlacionado com o termo de erro, o que violaria as suposições do modelo de mínimos quadrados ordinários (OLS).
- Interpretação: O alto valor de  $p$  (0,578) sugere que não há evidência de endogeneidade. Isso significa que, estatisticamente, o modelo OLS teria produzido estimativas semelhantes, e a endogeneidade pode não ser um grande problema neste caso específico. No entanto, já estamos usando regressão IV, ainda é uma boa prática prosseguir com o método IV se a endogeneidade for uma preocupação teórica.

```
Call:
ivreg(formula = log(packs) ~ log(rprice) | salestax, data = c1995)

Residuals:
    Min       1Q   Median       3Q      Max
-0.64619 -0.07732  0.02981  0.11283  0.41904

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   9.7199      1.5141   6.420 6.79e-08 ***
log(rprice)  -1.0836      0.3166  -3.422  0.00131 **

Diagnostic tests:
              df1 df2 statistic  p-value
Weak instruments    1  46   40.956 7.27e-08 ***
Wu-Hausman          1  45    0.314   0.578
Sargan              0 NA        NA        NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1904 on 46 degrees of freedom
Multiple R-Squared: 0.4011,    Adjusted R-squared: 0.3881
Wald test: 11.71 on 1 and 46 DF,  p-value: 0.001313
```

# Referências

- Hlavac, Marek. 2022. Stargazer: Well-Formatted Regression and Summary Statistics Tables. Bratislava, Slovakia: Social Policy Institute. <https://CRAN.R-project.org/package=stargazer>.
- Kleiber, Christian, and Achim Zeileis. 2008. Applied Econometrics with R. New York: Springer-Verlag. <https://CRAN.R-project.org/package=AER>.